

FGSM

```
mtx@user-Super-Server:~/目标检测$ python3 whitebox_fgsm.py --load_model $MODEL --num_eval 100 --runs
1 --steps 30
Device: cuda
已存在 VOC2007 目录: ./data/VOCdevkit/VOC2007

[FGSM 第1次]
Clean: P=77.62% R=84.76% F=0.8103 Acc=68.11%
Adv:   P=0.34% R=4.13% F=0.0062 Acc=0.31%
攻击成功率(GT/图像): 98.88% / 89.01%
扰动: L2=9.9414 Linf=0.0500 MSE=0.000185 SSIM=0.9981 PSNR=37.45

=====
FGSM 汇总
=====
攻击成功率(GT级)均值: 98.88%
是否满足 >85%: True
```

FGSM 是一步式白盒攻击，仅计算一次梯度就生成对抗扰动，速度最快、扰动最小。

- Adv P=0.34%: 对抗图像精确率几乎为 0
- Adv R=4.13%: 对抗图像召回率几乎为 0，漏检极其严重
- Adv F=0.0062: 检测性能完全失效
- Adv Acc=0.31%: 检测完全失败
- GT 攻击成功率 98.88%: 三者最高，几乎 100% 破坏目标检测
- 图像攻击成功率 89.01%: 近 9 成图片完全检测失效，破坏力最强
- L2=9.9414: 三者中扰动幅度最小
- Linf=0.0500: 最大像素改动极小
- MSE=0.000185: 三者中图像失真最低
- SSIM=0.9981: 图像几乎与原图完全一致
- PSNR=37.45dB: 画质极高，完全无法察觉扰动

FGSM 一步生成最小、最隐蔽的扰动，却实现最高攻击成功率，高效且破坏力极强。

PGD

```
mtx@user-Super-Server:~/目标检测$ python3 whitebox_pgd.py --load_model $MODEL --num_eval 100 --runs
1 --steps 20 --alpha 0.001 --random_start

Device: cuda
已存在 VOC2007 目录: ./data/VOCdevkit/VOC2007

[PGD 第1次]
Clean: P=79.81% R=84.26% F=0.8198 Acc=69.46%
Adv:   P=1.18% R=7.87% F=0.0206 Acc=1.04%
攻击成功率(GT/图像): 93.00% / 79.07%
扰动: L2=21.0898 Linf=0.0500 MSE=0.000818 SSIM=0.9918 PSNR=30.88

=====
PGD 汇总
=====
攻击成功率(GT级)均值: 93.00%
是否满足 >85%: True
```

PGD 是迭代式白盒攻击，通过多次沿梯度上升方向微小更新扰动，逐步最大化模型损失，是最强的基础迭代攻击。

- Adv P=1.18%: 对抗图像精确率仅剩 1.18%，预测几乎全部失效
- Adv R=7.87%: 对抗图像召回率 7.87%，目标几乎全部漏检
- Adv F=0.0206: 综合检测性能几乎完全崩溃
- Adv Acc=1.04%: 整体检测准确率接近完全失效
- GT 攻击成功率 93.00%: 93% 的真实目标被攻击干扰失效，攻击效果极强
- 图像攻击成功率 79.07%: 近 8 成图片检测完全失效
- L2=21.0898: 扰动整体幅度中等
- Linf=0.0500: 最大像素改动限制为 0.05，扰动非常微小、人眼几乎不可见
- MSE=0.000818: 图像失真极小
- SSIM=0.9918: 图像结构几乎未改变
- PSNR=30.88dB: 画质极高，肉眼无法区分对抗样本

PGD 用极小的不可见扰动实现极强攻击，检测性能近乎完全失效，攻击效果优秀。

MI-FGSM

```
mtx@user-Super-Server:~/目标检测$ python3 whitebox_mifgsm.py --load_model $MODEL --num_eval 100 --run
ns 1 --steps 30 --alpha 0.001 --mu 1.2
Device: cuda
已存在 VOC2007 目录: ./data/VOCdevkit/VOC2007

[MI-FGSM 第1次]
Clean: P=82.61% R=86.10% F=0.8432 Acc=72.89%
Adv: P=3.94% R=19.34% F=0.0654 Acc=3.38%
攻击成功率(GT/图像): 81.05% / 63.04%
扰动: L2=18.8973 Linf=0.0300 MSE=0.000668 SSIM=0.9930 PSNR=31.76

=====
MI-FGSM 汇总
=====
攻击成功率(GT级)均值: 81.05%
是否满足 >85%: False
```

MI-FGSM 在迭代攻击中加入动量，稳定梯度方向，让攻击更易成功，稳定性优于普通 PGD。

- Adv P=3.94%: 对抗精确率略高于 PGD、FGSM，但仍极低
- Adv R=19.34%: 对抗召回率 19.34%，漏检严重但略好于另外两种
- Adv F=0.0654: 综合性能失效，但相对另外两种稍好
- Adv Acc=3.38%: 检测基本失效
- GT 攻击成功率 81.05%: 攻击效果对比其他两种攻击明显较弱
- 图像攻击成功率 63.04%: 失效图片占比三者最低
- L2=18.8973: 扰动幅度中等
- Linf=0.0300: 最大像素改动限制最严格（仅 0.03）
- MSE=0.000668: 失真程度中等
- SSIM=0.9930: 图像结构保持完好
- PSNR=31.76dB: 画质高，扰动不可见

MI-FGSM 因限制更严格、扰动更小，导致攻击成功率略低，但仍能让模型检测基本失效。

总结

FGSM 攻击扰动最小、成功率最高；PGD 攻击稳定且破坏力极强；MI-FGSM 受限
于更小扰动，攻击效果稍弱。三种白盒攻击均能在人眼无法察觉的微小扰动下，
让目标检测模型完全失效。继续增加 steps 的迭代次数可以继续显著增大攻击的
成功率，但是因为需要更长的运行时间所以本次报告中未展示。